Marp生成サンプル

HuBMAP - Hacking the Human Vasculature
Kaggleコンペ ソリューションまとめ

ベースはこれ。雑に再編集をかけました。:

リンク

結果

初めての金メダル。10位 / 1064チームでゴールド獲得。

10位

/ 1064チーム

Gold

メダル獲得

項目	内容
アプローチ	YoloV7-seg + 疑似ラベル + パラメータ調整
ポイント	データの扱い ＞ モデルの組み合わせ

コンペ概要

腎臓組織画像から微小血管構造をインスタンスセグメンテーションするコンペ

タスク

- 2次元PAS染色組織画像が入力
- 毛細血管・細動脈・細静脈などの微小血管をセグメンテーション
- 血管の検出結果のみがスコアリング対象

背景

- VCCFの改善が目的
- 微小血管の知識にはまだ不明点が多い

評価指標

- Average Precision（IoU ≥ 0.6）
- 正解マスクと6割以上重なっていれば検出とみなす
- 検出できている割合がスコアになる

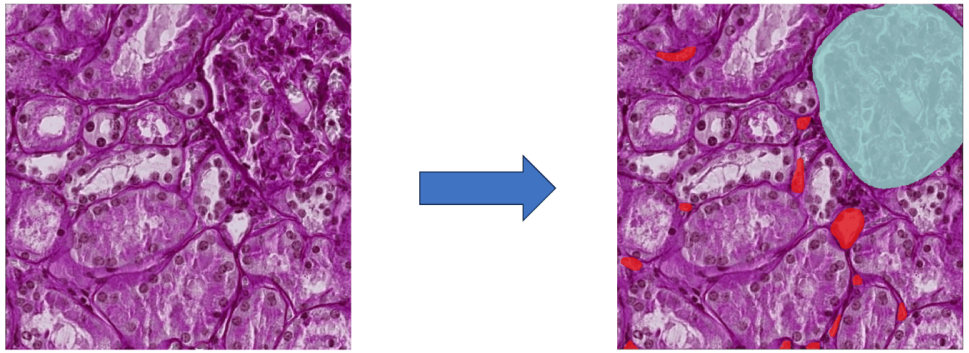

配布データの構成

14の病理サンプル × 2種類のアノテータ + ラベル無しで構成。
データの扱いがコンペ最大のポイント。

データ区分	アノテータ	枚数	備考
学習データ	専門家ラベル	422枚	高品質だが少量
学習データ	一般人ラベル	1,011枚	品質にばらつき
学習データ	ラベル無し	5,400枚	活用方法が鍵
テストデータ	専門家	???枚	Kaggleシステムで非公開

各病理サンプルは大きい画像を512×512に分割して配布。全14種のうち学習データは一部のみ。

ベースライン & アプローチ紹介

ベースライン：YoloV7-seg

物体検出のYOLOシリーズを拡張したインスタンスセグメンテーションモデルを使用

YOLOv7とは

- 物体検出で定評のあるYOLOシリーズの一つ
- 速度と精度のバランスに優れる
- YOLOv7-segはセグメンテーション拡張版

ベースラインの学習方法

- 専門家 + 一般人ラベルの1,433枚を全て学習
- 画像サイズは512×512のまま

アーキテクチャ

- 3段階のピラミッド構造
- 入力画像に対して1/4サイズでマスク生成

ベースラインの課題

検出精度が低い＆そもそも検出できていないという2つの課題があった

課題①：検出精度が低い

推定原因：

- 一般人ラベラーの品質が低く悪影響
  - 専門家はunsureラベルを付与、一般人はunsureが少ない
  - 一般人は異なるモノを血管としてアノテーション
- YOLOの入力画像サイズが小さい
  - 1/4サイズのマスクで小さい血管が消失

課題②：そもそも検出できない

推定原因：

- 病理サンプル1～4のみでは学習ドメインが狭い
- 未知のテストデータで性能が出ない
- T-SNEで可視化すると、未ラベルデータは学習データと異なる領域に分布

最終ソリューション

疑似ラベルによるラベル無しデータ活用 + YOLOパラメータ調整が差異化ポイント

差異化ポイント①：疑似ラベル

- 半教師あり学習の技術
- ラベル無しデータを活用して性能向上

差異化ポイント②：パラメータ調整

- 入力解像度を512→640に変更
- 小さい物体の消失リスクに対応

推論時の工夫

- NMSコードを修正し、選択されたFoldのマスクを活用
- 後処理：connected componentで最大マスクのみ保持
- Dilationは使用しない（後述）

疑似ラベルを使った多段階学習フロー

広いドメインで事前学習 → 専門ラベルで仕上げ、を多段で実施

1段階目：疑似ラベル付け準備

1. 一般人ラベルで事前学習（1fold, 100ep）
2. 専門ラベルでFinetuning（5fold, 100ep）
3. 未ラベルデータを予測 → 疑似ラベル生成
    - Conf > 0.5（インスタンス）
    - 平均Conf > 0.6（タイル）で選定

2段階目：提出モデル作成

1. 疑似ラベルで事前学習（1fold, 100ep）
2. 専門ラベルでFinetuning（5fold, 100ep）
   → 最終提出モデル

YOLOパラメータ調整

入力解像度を512→640に変更し、小さい血管の消失リスクに対応

変更内容

- 配布画像は512×512だが、640×640にリサイズして推論
- 一見意味なさそうだが効果あり

理由

- YOLOv7は入力を1/4に縮小してマスク生成
- 512入力 → 128マスク → 小さい血管が消失
- 640入力 → 160マスク → 小さい血管を保持

推論パラメータ

パラメータ	値
Resolution	640
Conf threshold	0.001
IoU threshold	0.55
Folds	0, 1, 4
Dilation	使用しない
後処理	最大マスク保持

上位陣との共通ポイント

コンペの勝敗を分けたのは、Clean Dataを見つける・作成する能力

Dilationの罠

- コンペ中、Dilation処理で性能向上という情報が流通
- しかし結果的にDilation使用者はランキングダウン
- 画像端での漏れ補完に効いていただけとの推測

データセットの信頼性判断

- 上位陣は一般人ラベルの不確かさを正しく見極めていた
- Pseudo Labeling（疑似ラベル）で付け直す処理が共通
- 結論：データの扱い ＞ モデルの組み合わせ

入賞に必要だったもの

さらに上位に行くには、複数モデルのアンサンブルが必要だった

順位	手法
我々（10位）	YOLOv7のみ
3位	ViT、CBNetV2、ResNext101D などのアンサンブル
4位	MaskRCNN、CascadeRCNN、HTC、YOLOv6 のアンサンブル

→ 単一モデルでの限界。複数アーキテクチャの組み合わせがトップ入りの条件。

うまくいかなかったこと・やれなかったこと

試行錯誤の中で、効果がなかったもの・実現できなかったものも多い

うまくいかなかった

- 疑似ラベル付与を2周実施
- YOLOv8での学習・推論
- NMS → WBF への変更

うまく実装できなかった

- タイルを結合して再生成したデータでの学習

やれなかった

- Stain toolによるデータ水増し
- 外部データを使った学習

提出できなかった最高性能モデル

- 入力解像度を800まで上げたモデル
- 小さい認識結果の影響度が高かった可能性

参考にした関連コンペ

過去コンペのソリューションが、疑似ラベル戦略の着想源になった

コンペ	参考にしたポイント
Global Wheat Detection（物体検出）	疑似ラベル付与の手法
Sartorius - Cell Instance Segmentation（インスタンスセグ）	疑似ラベル + 最後のファインチューニングの思想

まとめ

- 順位: 10位 / 1064チーム（ゴールド）
- 手法: YoloV7-seg + 疑似ラベル + パラメータ調整
- 最大の学び: データの扱い ＞ モデルの組み合わせ
- 専門ラベル・素人ラベル・未ラベルの使い分けがポイント
- 疑似ラベルで良質なデータを選定する戦略が性能に直結
- 上位に行くにはアンサンブルが必要だった
- 所感: モチベーションコントロールが課題。過去コンペのソリューション参考の重要性を再認識